

測試計畫書

兒童注意力監測與量化分析平台

Attention Assessment System for ASD and TD Children

組員：B1109240劉立綸、B1229011李瑋恆、B1229056黃昱翔、B1229059黃璿軒

建立日期：2026 年 9 月 15 日

魏志遠

1. 測試計畫名稱與編號

測試計畫名稱：兒童注意力監測與量化分析平台功能測試計畫

本計畫涵蓋完整原始碼（main.py、hurry/main.py、modules/*、ui/*、summarize/*），以及專案自身持續累積的問題追蹤文件《程式碼問題清單_對照人工AI差異.md》。（此文件已結案並轉為歷程紀錄，現行待辦改記於《程式問題清單_V2.md》）

2. 簡介

2.1 計畫目的

本系統主要協助研究人員進行自閉症類群障礙(Autism Spectrum Disorder, ASD)兒童與典型發展(Typical Development, TD)兒童的注意力差異評估,特別針對共同注意力(Joint Attention)中的反應性共同注意力(Responding to Joint Attention, RJA)能力進行量化分析，將於標準化測試情境中（測試物可能為氣球、機器玩具等），以電腦機器學習技術自動判定「兒童是否將注意力聚焦於指定測試物」，並產出可供臨床參考的時間序列事件與統計指標。

2.2 計畫範圍

技術範圍：

- 視覺分析模組：利用MediaPipe Face Mesh檢測人臉特徵點，再利用solvePnP 得出頭部旋轉矩陣和平移向量（頭部姿態估計），接著進行圖像正規化、神經網絡推理得出視線向量，最後將視線向量轉換出現在畫面中。
- 語音觸發模組：整合 OpenAI Whisper (large-v3) 語音辨識技術，自動擷取測試員之提示關鍵字，建立動態判定視窗。
- 邏輯判定與輸出：定義貪婪排他性綁定 (Greedy Bipartite Matching) 演算法，以及注意力/指向事件之量化紀錄與報表輸出格式。本文件不涉及硬體攝影機之內部電路設計，聚焦於軟體系統之功能邊界與驗收標準。

功能範圍：

- 輸入端：接收研究人員拍攝之固定視角實驗研究影片(MP4)，以及預設之階段提示字卡影像檔
- 處理端：進行多模態 AI 聯合推論，包含物件追蹤、視線方向、手勢姿態之視覺辨識，以及關鍵字語音特徵之提取與分析。
- 輸出端：利用.bat檔產生的UI介面，進行一系列操作並產生視覺化分析影片，並匯出包含時間戳記與注意力事件之數據報表。

使用情境：

- 單一受試者測驗(一對一評估)
- 控制環境(固定測驗室設置)
- 研究人員在場操作拍攝影片與觀察

2.3 參考文件

YOLO (You Only Look Once) 官方文件 - <https://docs.ultralytics.com/>

MediaPipe 官方文件 - <https://developers.google.com/mediapipe>

OpenCV 技術文件 - <https://docs.opencv.org/>

Robotflow官方網頁-<https://roboflow.com/universe>

OpenAI Whisper 官方技術文件 - <https://github.com/openai/whisper>

ETH-XGAZE 官方技術文件 - <https://github.com/xucong-zhang/ETH-XGaze>

MPIIGAZE 官方技術文件 - https://github.com/hysts/pytorch_mpiigaze_demo

視線估計 (Gaze Estimation) 論文文件- https://www.ecva.net/papers/eccv_2020/papers_ECCV/papers/123500358.pdf

臉部正規化 (Normalization) 論文文件 - https://www.collaborative-ai.org/publications/zhang18_etra.pdf

3. 測試項目

3.1 操作測試

驗證三種既定的操作方式都能正常啟動並跑完既定流程：

操作方式	進入點	驗證重點
批次分析	python hurry/main.py	自動掃描 hurry/video/ 底下所有影片，逐支處理直到全部完成；已存在完整輸出的影片自動跳過
完整版分析	python main.py	互動輸入影片編號、手動框選牌子 ROI，跑完 Stage 1~14
圖形化介面	run_ui.bat / python ui/app.py	雙擊或指令啟動，四個頁籤（影片載入設定／即時監測／單次報表／歷史統計）皆可切換

本輪測試已實際執行「圖形化介面」一項的啟動驗證，過程中發現並修復三項環境缺陷（詳見 6.1 節），修復後介面成功啟動；「批次分析」亦已實際執行 10 支 benchmark 影片（詳見 3.5、6.5 節）；「完整版分析」本輪未執行，留待後續測試。

3.2 功能測試

針對計分核心邏輯的單元測試（本輪已用 pytest 實作並執行，詳見第 6 節）：

測試對象	測試檔案	驗證內容
GazeHoldTracker (modules/gaze_hold.py)	tests/test_gaze_hold.py	原始命中即時反映、單側遲滯橋接短暫漏偵測、新命中打斷對側殘留遲滯（防止 TB/TH 同幀誤判）、reset() 正確歸零
Stage 1 Fallback 時機 (scoring_engine.py)	tests/test_scoring_engine_fallback.py	無語音事件時，Fallback T0 於門檻秒數前不建立、門檻秒數後正確建立
Stage 9/10 關鍵字比對 (scoring_engine.py)	tests/test_scoring_engine_stage9_10_keywords.py	裸字關鍵字（「畫」「三」）不誤觸發，具體片語（「畫一幅」「煙火」）正確觸發

此外，功能測試亦涵蓋以下既有機制（透過整批影片驗證間接檢驗，見 3.5）：

- 依 OCR 讀到的階段牌動態切換 YOLO 模型 (models_manager.py 的 Lazy Loading)
- noise.wav 樣板比對（餘弦相似度 ≥ 0.7 ）觸發 Stage 8 T0
- TB / TH 交替計次鎖 (_last_counted_target) 與 1.5 秒冷卻時間
- Whisper 語音辨識快取機制（同一影片第二次分析不重跑轉錄）

3.3 介面測試

圖形化介面（ui/）之基本可用性：

- qt_compat.py 相容層：優先載入 PySide6，找不到時退回 PyQt5，兩者皆無時給出明確安裝指示
- 四個頁籤（① 影片載入與設定 ② 即時監測 ③ 單次結果報表 ④ 歷史統計比較）皆可正常渲染與切換
- 「推論裝置」與「視線推論裝置」磚須正確顯示 GPU／CPU 狀態
- 深色主題（theme.py）樣式正確套用，中文文字不因 QPainter 自繪圖表而變成方塊
- 語音子行程（speech_engine.py）於 pythonw.exe 無主控台環境下不應因編碼問題（UnicodeEncodeError）崩潰

本輪已實際啟動 UI 並截圖驗證第一頁「影片載入與參數設定」正確渲染，結果見 6.3 節。

3.4 績效測試

評估在既定硬體環境下的推論效能與資源使用：

項目	衡量方式	本輪實測參考值
GPU 推論可用性	torch.cuda.is_available()、視線/YOLO 模型是否走 CUDA	已確認 RTX 5060 Ti 於 CUDA 12.8 建置下正確被偵測（詳見環境修復紀錄）
Whisper VRAM 降級機制	large-v3 FP32 約需 8~10GB VRAM，不足時應自動退回 CPU 並於主控台明確提示	本輪批次因主控台輸出被緩衝機制吃掉，未能截取到降級訊息，列為待改善項目
批次吞吐量	10 支 benchmark 影片全部處理完畢所需總時間	3 小時 15 分（10 支，平均每支約 19 分鐘，含全新 Whisper 轉錄）

3.5 品質測試

以 10 支 benchmark 影片（編號 42、49、52、64、66、74、82、86、90、104）為樣本，比對系統輸出與人工 ground truth（docs/人工-AI結果差異對照表.xlsx）之間的一致性，並與既有基準結果（原始數據）做逐支逐關比對，找出等級變化與可能的迴歸。本輪測試特別關注：

- 三個已知指向真陽性紅線（42-S4、49-S7、52-S7）是否因程式修改而被誤殺
- Stage 3 已知的 TH 真陽性群組（49、64、82、86、90、104）是否維持正確判定
- TB / TH 在同一時間戳同時成立的異常訊號（遲滯殘留假象）出現頻率
- 任一關卡等級（F / LR / HR / LI / HI）相對於基準結果的變化方向與可解釋性
- 本 10 支 benchmark 樣本對全量人工真陽性的代表性有限：TH 涵蓋 15.7%（77/491 格）、指向僅涵蓋 12.8%（5/39 格），本輪品質測試通過不代表指向相關修改已在全量資料上獲得驗證（詳見《程式問題清單_V2.md》N2）

4. 測試方法

4.1 測試環境需求

項目	需求
作業系統	Windows 10 / 11 (64 位元)
Python 環境	3.9, conda 環境 mediapipe_py39
顯示卡	NVIDIA GPU, 建議 CUDA 12.x 對應驅動 (RTX 50 系列須 CUDA 12.8 以上才能被偵測)
顯示記憶體	Whisper large-v3 (FP32) 約需 8~10GB; 不足時自動退回 CPU, 速度大幅下降
硬碟空間	至少 20GB 可用空間 (模型權重、暫存快取、輸出影片)
單元測試框架	pytest (需另行 pip install, 並設定 pytest.ini 的 pythonpath=, 以便 import modules)
其他工具	ffmpeg (已內附)、EasyOCR/Ultralytics 模型快取需已安裝於使用者目錄

4.2 測試項目的通過準則

測試項目	通過準則
操作測試 (3.1)	三種操作方式皆能在無例外中止的情況下跑完既定流程, 並產生格式正確的輸出檔
功能測試 (3.2)	pytest 全數測試案例通過 (本輪為 8/8: GazeHoldTracker 5 項、Stage1 Fallback 1 項、Stage9/10 關鍵字 2 項)
介面測試 (3.3)	UI 視窗成功開啟並顯示第一頁, 四個頁籤皆可切換不崩潰, 語音子行程不因編碼問題中止
績效測試 (3.4)	GPU 被正確偵測並用於推論; VRAM 不足時能明確降級而非直接崩潰
品質測試 (3.5)	已知真陽性 (指向 3 例、Stage 3 TH 6 例) 不得被誤判為陰性; 任何等級變化須能追溯到具體修改並附時間戳證據, 不得是無法解釋的隨機波動 (注意: 本 10 支 benchmark 對全量指向真陽性僅涵蓋 12.8%、對 TH 僅涵蓋 15.7%, 通過本準則不代表指向修正已於全量資料驗證, 需另行規劃更具代表性樣本)

4.3 測試中止的準則與再繼續的需求

符合下列任一情況應中止當次測試, 排除原因後再繼續:

- GPU／CUDA 無法被偵測，導致單支影片預估處理時間超出可接受範圍（免安裝版文件記載無 GPU 時 6 分鐘影片可能需數小時）
- 既有的 Whisper 語音快取（_speech_*/資料夾）遺失或損毀——語音重新轉錄成本高，應先確認快取完整再繼續批次跑，而非整批重跑
- 批次程序自身以非 0 狀態碼結束，且無法從既有紀錄確認是收尾階段的無害問題，還是真正的處理中斷
- 再繼續的需求：確認上述問題已排除（GPU 驅動更新、快取復原、程序改用 python -u 以便截取完整主控台輸出）後，方可重新啟動測試

4.4 測試交付項目

- 10 支 benchmark 影片的批次分析報告（{編號}.txt）與逐支逐關差異比對表（task-8-baseline-diff.md）；後續待辦已移至《程式問題清單_V2.md》，作為下一輪測試的輸入
- 更新後的《程式碼問題清單_對照人工AI差異.md》，記錄本輪測試發現的所有現象與後續建議
- 本測試計畫書

4.5 測試工作項目與時程

版本	主要內容	日期
v1	具備「眼神接觸（eye contact）」判定的最初可行版本（相對於前一版 v0「無眼神接觸判定」）	2026-06-15
v2	上傳版本 v2	2026-07-01
v3	上傳版本 v3	2026-07-07
v3.5	v3 的快速修正版本	2026-07-08
v4	上傳版本 v4	2026-07-08
v5	持續漸進修正：更新 Stage 10 判定、補齊部分階段的記錄缺漏、更新視線與計次判定、更新批次版主程式	2026-07-11 ~ 2026-07-17
v6	上傳版本 v6，修改 Stage 11-14 判定；後續持續優化指向判定邏輯（interaction.py）、新增判定結束時間紀錄、更新統計彙整模組（summarize）	2026-07-20
v7	上傳版本 v7，新增圖形化使用者介面（UI）	2026-09-13
v7.5	上傳版本 v7.5，並更新程式、修改 README	2026-09-15

5. 人員配置與訓練需求

5.1 測試人員配置

角色	負責項目
專案負責人 / 研究者	測試需求確認、對照人工 ground truth 之最終判定、發布決策
AI 工具協作開發	單元測試撰寫與執行、批次驗證執行與監控、結果比對分析、文件記錄與審查

5.2 訓練需求

- 熟悉本系統 T0 / TB / TH / Pointing 的判定規則與各關卡（Stage 1～14）之對應目標物
- 熟悉 pytest 基本用法，能獨立新增針對 scoring_engine.py 的回歸測試案例
- 熟悉 conda 環境管理，能辨識 mediapipe_py39 與其他無關環境（.venv、attention_integrate 等）的差異
- 熟悉 docs/人工-AI結果差異對照表.xlsx 的欄位定義（依標題列 _n 後綴分關卡、依欄位順序判斷人工／AI 角色）

6. 測試結果與審查

6.1 功能測試結果

pytest 全數測試通過：8/8（GazeHoldTracker 5 項、Stage 1 Fallback 1 項、Stage 9/10 關鍵字 2 項）；所有案例皆先確認在未修正前會失敗、修正後才通過，排除了無效測試的可能。

6.2 介面測試結果

UI 主視窗成功開啟，顯示「①影片載入與參數設定」頁，側邊四頁籤導覽、分析參數面板、影片來源選擇區皆正確渲染（畫面截圖存於本機 schematic_diagram/ 目錄）。修復 6.1 節缺陷後，「推論裝置」與「視線推論裝置」磚正確顯示 GPU／CUDA，而非修復前的 CPU。「即時監測」「單次結果報表」「歷史統計比較」三頁本輪未逐一操作驗證，僅完成第一頁渲染與裝置狀態確認。

6.3 績效測試結果

GPU 推論修復後確認可正常運作（見 6.1 節）。10 支 benchmark 影片批次分析總耗時 3 小時 15 分，平均每支約 19 分鐘（含 9 支全新 Whisper 轉錄、1 支沿用既有語音快取）。批次程序本身

於全部影片皆產出完整輸出後，以非 0 狀態碼 (exit code 1) 結束；因主控台輸出被緩衝機制吃掉、未能截取到錯誤訊息，研判為收尾階段背景執行緒 (Whisper 子行程或 CUDA context) 未乾淨結束，非分析失敗，但無法百分之百排除，列為 6.6 節的後續建議之一。

6.4 品質測試結果

10 支 benchmark 影片與既有基準比對後發現：7/10 支影片 Total Score 較基準下降，共 9 處關卡等級下降，型態皆為「TH (看回施測者) 由有達成變成完全未達成」。

經最終整體審查以模擬程式驗證：其中 6 處 (TB/TH 時間差 < 0.35 秒) 符合視線遲滯機制修正 (A4/A5) 的預期效果，判定為系統正確移除過去未被發現的遲滯殘留假陽性；另外 3 處 (82-S1、86-S2、104-S7) 時間差遠超過該修正理論上可能影響的範圍，經程式碼追查，初步鎖定為 Stage 1 Fallback 延遲時間調整 (C4) 與 Stage 9 關鍵字收窄 (C2) 各自觸發了既有架構中兩個先前未被記錄的跨關卡耦合所致，詳細機制與建議診斷步驟已記錄於《程式碼問題清單_對照人工AI差異.md》第 1-5 節。

三個已知指向真陽性紅線 (42-S4、49-S7、52-S7) 以及既有的 Stage 3 TH 真陽性群組，本輪測試皆未被誤殺；手臂共線性 45° 門檻 (B1) 與施測者頭部框判定邏輯 (A1) 之修改，均未觀察到副作用。

Stage 9/10 關鍵字具體化 (C2) 與 Stage 1 Fallback 延遲調整 (C4)，其修改邏輯本身皆已經 pytest 合成資料驗證正確；但在這 10 支 benchmark 影片中，因逐字稿內容恰好沒有觸發其原本要防範的情境，故未觀察到直接的正面效益，其負面的跨關卡副作用則如上述另行發現。

6.5 整體審查結論

整體程式碼審查 (涵蓋本輪全部修改檔案) 之結論為：本輪修改本身的實作邏輯正確，但整體結果的可歸因性仍待下一輪隔離驗證後才能確認。造成此結果的主要原因並非任何單一修改的實作錯誤，而是：

- 本輪同時合併了視線遲滯、指向判定與計分邏輯共 7 項修改，未依專案既定的「一次只改一組」方法論分批驗證，導致觀察到的現象無法單獨歸因 (各項修改代號詳見《程式碼問題清單_對照人工AI差異.md》)
- 發現兩個既有架構中從未被文件記錄的跨關卡耦合 (T0 確定後暫存緩衝區的丟棄邏輯；Stage 9 關鍵字反向限制 Stage 8 候選時間的過濾條件)，其修正超出本輪任務原訂範圍，需另行規劃

6.6 後續建議

- 拆開重跑，隔離驗證視線遲滯相關三項修改 (A4、A5、A6) 對 9 處 TH 消失現象的個別貢獻比例
- 針對 82-S1、86-S2、104-S7 三個異常案例，對照人工 ground truth 或直接複核輸出影片畫面，確認修正方向正確與否

- 後續批次執行建議加上 `python -u` 或設定 `PYTHONUNBUFFERED=1`，避免主控台輸出因緩衝機制遺失，影響問題排查；亦有助於確認 6.4 節批次程序結束時 `exit code 1` 的確切原因
- 完整版分析（`main.py`）與 UI 的「即時監測」「單次結果報表」「歷史統計比較」三頁本輪未實際操作驗證，建議排入下一輪操作測試與介面測試
- 在 `_apply_frame_to_record` 中補上「TB/TH 被攔截時的原因」記錄（交替鎖／冷卻時間／關卡不符等），讓「事件未發生」與「事件被攔截」可被區分
- 完整發現與逐項證據請見《程式碼問題清單_對照人工AI差異.md》第 1-5 節（診斷歷程，已結案）；現行待辦與下一輪執行順序請見《程式問題清單_V2.md》。