

•••••

# 兒童注意力監測系統

指導教授：魏志達 教授

組員：劉立綸、李瑋恆、黃昱翔、黃璿軒

合作對象：


林口長庚早療中心主任、長庚大學早療所所長陳  
嘉玲教授

長庚大學早療所研究助理鄭喬方


魏志達



報告日期：6/1（一）



# 目錄



## ➔ 模型訓練

使用yolo訓練模型識別物件  
新增遠端指物與近端指物

## ➔ 手勢向量分析

結合 YOLO 與 MediaPipe 雙模型，  
判別指向向量

## ➔ 語音辨識


音訊擷取與前處理、Whisper 語  
音辨識、關鍵提示詞偵測、事件  
時間窗觸發、語音事件紀錄輸出

## ➔ 視線追蹤

人臉特徵點檢測、頭部姿態估計  
、圖像正規化、神經網絡推理  
、視線向量轉換

# 類別圖與系統架構圖


## → 類別圖



本圖為 UML 類別圖（Class Diagram），用來描述系統中各主要類別的屬性、方法，以及類別之間的組合關係。IntegratedAttentionSystem 作為核心控制類別，組合了 AudioEngine、VisionEngine、GazeEngine、CollisionLogicEngine 與 OutputManager 等模組，共同完成影片分析、語音處理、視線估計、碰撞判斷與結果輸出



## 系統架構圖



本圖為系統分層架構圖，接近 UML 中的 **Component Diagram**，用來表示各模組之間的資料流與處理關係。系統分為資料擷取層、AI 推論層、分析與邏輯層三個部分。


•••••

# 模型訓練

更新玩具模型的內容與場景複雜度。用新的收案影片作為素材的資料及進行訓練

新的遠端指物模型一開始訓練方向錯誤導致效果不佳，經過調整與新增鏡像後的成果有待驗證


近端指物經過收案影片與實體物品的拍攝後，素材數量得到很大的提升，產生的訓練模型成果有待驗證



玩具模型



遠端指物模型



近端指物模型

# 手勢指向分析

在臨床評估實驗的第八階段，系統需判定兒童是否正確關注機器人所指示的目標物。由於機器人具備非標準的人體結構，傳統姿態估計模型無法直接套用。本系統透過定製化 AI 模型與平滑演算法，精準萃取機器人的指向意圖。

## 1 非標準人體結構 (Structural Incompatibility)

既有的人體姿態估計模型（如 MediaPipe、YOLO-Pose）無法有效辨識機器人的機械手臂與外觀，導致系統在進入機器人互動階段時出現判定盲區與追蹤遺失。

## 2 專屬視覺模型訓練 (Custom Model Training)

針對機器人的特定外觀，額外標註並訓練輕量化的 YOLO 單關鍵點模型。系統會自動鎖定機器人的「手臂邊界框 (BBBox) 中心」與「指尖關鍵點」，精準提取所需的空間座標。

## 3 動態射線與平滑穩定 (Dynamic Ray & Stabilization)

計算上述兩點的空間向量以生成虛擬的指向射線。為解決單幀預測容易產生射線閃爍的問題，系統導入時序平滑演算法 (SMA Buffer) 動態過濾雜訊，確保射線如實體雷射般穩定，並進行最終的目標物碰撞判定。



# 語音辨識

在臨床評估情境中，治療師常透過口語提示引導兒童注意指定目標，例如「開始」、「準備」、「你看」、「看這裡」等。為了讓後續視線與手勢分析有明確的判定起點，本系統導入語音辨識模組，自動擷取語音內容、偵測關鍵提示詞，並建立反應時間窗，作為共同注意力分析的事件觸發依據。

- 1

### 語音轉文字 (Speech-to-Text)

系統採用 Whisper 模型對實驗影片中的語音進行辨識，將治療師口語提示轉換為逐字稿，作為後續事件分析基礎。
- 2

### 關鍵詞觸發 (Keyword Triggering)

針對 開始、準備、你看、看這裡 等提示詞進行偵測；當系統辨識到關鍵語句時，即標記對應時間點。
- 3

### 反應時間窗建立 (Reaction Window)

在偵測到提示詞後，自動開啟 3 秒 判定時間窗，提供視線估計與手勢分析模組進行後續共同注意力判斷。

```
1  === 影片語音逐字稿 (含觸發事件紀錄) ===
2  影片：/Users:/huangyuxiang/Documents/早療所專案/video/8.mp4
3  模型：large-v3
4  反應時間：3.0 秒
5  關鍵字：開始、321、三二一、3 2 1、準備、你看、看這裡、準備囉
6  觸發次數：4
7
8  === 逐字稿 ===
9  [00:00 - 00:02] 請問你叫什麼名字
10 [00:02 - 00:03] 我叫雞河
11 [00:03 - 00:06] 那你可以幫我把口罩拿下來嗎
12 [00:07 - 00:09] 好 謝謝你
13 [00:12 - 00:14] 其實你要去找磨砧罷
14 [00:14 - 00:16] 好 這還嗎
15 ★ [00:16 - 00:18] [觸發：你看] 雞河你看
16   -> 判定視窗：16.000s ~ 19.000s
17 [01:00 - 01:06] 小朋友你好
18 [01:06 - 01:10] 很开心你今天来这里玩
19 [01:10 - 01:13] 等等我要用笔写一些字哦
20 [01:13 - 01:15] 好
21 [01:15 - 01:28] 我很厉害吧
22 [01:28 - 01:30] 好
23 [01:30 - 01:32] 很高興認識你
24 [01:32 - 01:34] 拜拜
25 [01:40 - 01:42] 這個袋子裡面有些玩具
26 [01:42 - 01:44] 你可以把它
27 [01:44 - 01:46] 拿出來玩
28 [02:28 - 02:30] 喵喵喵喵
```

# 視線估計


## Gaze Estimation

### 實際碰上的問題：

幼兒園小朋友進行視線追蹤時，由於幼兒其面部佔比過小以及身形比例與成人存在顯著差異，原本單用MediaPipe特徵點提取針對成人優化的偵測器容易失效。

### 解決方法：

改用「YOLO 頭部檢測 + MediaPipe 特徵點提取」的兩階段策略（Two-stage Pipeline），並引入空間先驗（Spatial Prior），以畫面中心部分為優先檢測，以此減少誤判機率外，同時達到提取的畫質像素較高，較容易檢測到人臉。



- stage1:face detection
- stage2:head pose
- stage3:normalization
- stage4:gaze network
- stage5:gaze vector